

超网络：用于高光谱变化检测的自监督高光谱空谱特征理解网络

Meiqi Hu, Graduate Student Member, IEEE, Chen Wu¹, Member, IEEE, and Liangpei Zhang¹, Fellow, IEEE

摘要 - 自监督学习 (SSL) 的快速发展降低了从海量无标记数据中学习特征表示的门槛, 并引发了一系列关于遥感图像变化检测的研究。将 SSL 从自然图像分类应用于遥感图像变化检测所面临的挑战源于这两项任务之间的差异。所学习的补丁级特征表示无法满足像素级精确变化检测的需求。在本文中, 我们提出了一种新颖的像素级自监督高光谱空谱特征理解网络 (Hyper-Net), 以实现逐像素的特征表示, 从而进行有效的遥感变化检测。具体而言, 不是将补丁而是将整个图像输入到网络中, 并逐个像素比较多时相空谱特征。不是以混合方式处理二维成像空间和频谱响应维度, 而是提出了一个强大的空谱注意力模块, 分别探索多时相高光谱图像 (HSI) 的空间相关性和有判别性的频谱特征。仅创建双时相高光谱图像相同位置的正样本, 并强制使其对齐, 旨在学习频谱差异不变特征。此外, 提出了一种名为焦点余弦的新相似性损失函数, 以解决不平衡的易和难正样本比较问题, 其中增加并突出这些难样本的权重, 以促进网络训练。已采用了六个高光谱数据集来测试所提出的超网络的有效性和泛化能力。大量实验表明, 在下游高光谱变化检测任务中, 超网络优于最先进的算法。

索引术语 - 特征理解、高光谱变化检测、像素级别、自监督学习 (SSL)、空谱注意力 (SSA)

变化检测技术是城市发展监测以及土地覆盖/土地利用变化检测的重要工具[1]、[2]、[3]。一般来说, 变化检测

是指检测在同一地点不同时间获取的两幅遥感图像的变化[4]、[5]。高光谱图像 (HSI) 通常由数十到数百个光谱波段组成[6]、[7], 为各类地物提供了独特的光谱曲线和丰富的光谱信息, 在物体判别和分类方面显示出巨大潜力[8]、[9]。高光谱变化检测有利于区分难以察觉的变化。两个重要任务分别是高光谱异常变化检测 (HACD 任务) 和一般高光谱二值变化检测 (HBCD)。HACD 任务[10]、[11]侧重于通常由小而稀有的物体的位移、外观、消失和隐蔽性所产生的变化。HACD 任务旨在突出这些稀有变化, 用于防空和应急响应等。而 HBCD 旨在检测在复杂情况下精确的土地覆盖变化, 即在某些非常相似的地物之间可能发生的变化[12]、[13]。

近年来, 深度学习的增加显著促进了变化检测算法的发展[14]、[15]、[16]、[17]。当前大多数高光谱变化检测方法主要基于深度监督学习[18]、[19], 其中模型训练需要训练标签。高质量的训练数据确实为参数训练提供了准确的监督, 并带来了良好的性能, 但获取这些数据既费力又难以获得。因此, 减轻或消除对标注标签的依赖成为高光谱变化检测问题的关键。

自监督学习 (SSL) [20]、[21]、[22]是机器学习中一种新的范例, 使模型能够从大量无标签数据中学习特征表示。它为自然图像处理激发了大量的 SSL 表示学习算法。作为一种有判别性的 SSL, 对比学习 (CL) [23]、[24]旨在将正样本对拉近, 将负样本对拉开, 并已被应用于多光谱光学和合成孔径雷达 (SAR) 遥感变化检测[25]、[26]。然而, 高光谱变化检测的自监督学习仍然面临以下限制。

Manuscript received 19 July 2022; revised 21 September 2022; accepted 13 October 2022. Date of publication 1 November 2022; date of current version 17 November 2022. This work was supported in part by the National Natural Science Foundation of China under Grant T2122014, Grant 61971317, and Grant 42230108. (Corresponding author: Chen Wu.)

The authors are with the State Key Laboratory of Information Engineering in Surveying, Mapping and Remote Sensing, Wuhan University, Wuhan 430079, China (e-mail: meiqi.hu@whu.edu.cn; chen.wu@whu.edu.cn; zlp62@whu.edu.cn).

Digital Object Identifier 10.1109/TGRS.2022.3218795

1558-0644 ©2022 IEEE. Personal use is permitted, but republication/redistribution requires IEEE permission. See <https://www.ieee.org/publications/rights/index.html> for more information.

授权许可使用仅限于: 河海大学图书馆。于 2024 年 12 月 5 日 15:45:40 协调世界时从 IEEE Xplore 下载。有限制。

A. 用于精确变化检测的像素级特征表示

当前基于SSL的变更检测方法本质上依赖于实例判别。具体来说，多时相图像被分割成补丁以供模型输入。这些补丁被映射到特征空间中的特征向量，以进行特征比较。结果，模型只能学习到补丁级别的特征表示，导致变更检测结果粗糙。

B. 空间和频谱特征的充分利用

由于多时相复杂地物可能因光谱差异的变化而混淆，空间和频谱特征提取在高光谱变化检测中至关重要。一个常见现象是，大多数基于深度学习的变化检测方法采用二维卷积层同时提取空间和频谱特征。然而，由于空间核滤波器沿水平和垂直方向滑动，二维卷积层专注于每个通道的空间信息，但忽略了不同频谱波段之间的关系，导致频谱信息的有效利用不足。

鉴于上述问题和关注点的考虑，提出了一种自监督高光谱空谱特征理解网络（HyperNet）。为了在诸如变化检测等密集预测任务中实现像素级特征，我们提出了一个原始的全卷积 SSL 框架，以便方便地进行逐像素特征学习。在完全无标签数据中进行细粒度对齐时，在像素级别而非补丁级别对多时相高光谱图像进行相似性比较。并且设计了一个强大的空谱注意力（SSA）模块，以充分挖掘信息丰富的空间和频谱特征，包括空间注意力分支和频谱注意力分支。前者用于探索空间特征并选择性地强调最具信息量的空间对象。后者旨在充分利用有判别力的频谱信息以及局部和全局频谱波段之间的关系。分别从所提出的两个分支中提取深层空间和频谱特征，然后自适应地融合以产生综合特征。考虑到自监督学习（SSL）中简单样本和困难样本不平衡的情况，提出了一种名为焦点余弦（cos）的新损失函数，以增大困难样本的权重并促进网络训练。我们探索了所提出的自监督超网络在两种变化检测任务（即 HACD 任务和 HBCD）上的泛化能力，因为 SSL 以学习通用特征以及对不同下游任务的强大泛化能力而闻名。本文的贡献可概括为三个部分。

- 1) 为高光谱变化检测精心设计了一个自监督超网络。超网络成功实现了像素级的自监督特征表示学习，以完成精确的密集变化检测任务。并且分别设计了一个空间注意力分支和一个频谱注意力分支，以分别提取有判别力的空间和频谱信息，而不是以混合方式直接处理高光谱图像。

- 2) 为了缓解 SSL 训练中容易的阳性样本和困难的阳性样本之间的不平衡问题，提出了一种新颖的相似性损失函数，名为焦点余弦损失，以强调困难阳性样本的权重，并缓解大量容易样本的主导地位。在六个高光谱变化检测数据集上的实验结果表明了所提出的焦点余弦损失函数是有效的。

- 3) 为了证明所提出的超网络的有效性，我们在 HACD 任务和 HBCD 上进行了大量实验。超网络在 HACD 任务和 HBCD 结果上都表现良好，优于最先进的算法，证明了所提出的分别提取空间和频谱特征以更好地理解高光谱图像的有效性和泛化能力。

本文的结构如下。第二部分将对相关工作进行简要介绍。第三部分将详细介绍所提出的超网络。第四部分将展示实验结果和分析。第五部分将展示关于消融实验的讨论。最后，第六部分将总结本文。

II. 相关工作

A. 高光谱异常变化检测

HACD 任务关注小物体的动态，面临着多时相高光谱图像不变区域之间剧烈频谱差异的挑战，这些差异主要是由复杂的大气状况和光照条件以及传感器运动等因素造成的[27]、[28]。基于预测器的方法是一种非常经典的解决方案，其中多时相高光谱图像一对像素的光谱值可以通过线性或非线性回归模型进行映射[29]、[30]。并且由预测器构建的预测图像对于那些不变背景区域（如植被和建筑区域）会被调整为与另一高光谱图像尽可能接近。因此，异常变化可以很容易地从残差图像中分离出来。时间色度（CC）

[31] 提出了一种线性空间不变观测模型，用于在两个高光谱图像之间建立线性映射，假设观测到的光谱值与真实原始光谱曲线呈线性回归。然而，非均匀的光谱差异场导致线性模型性能不佳，尤其是在不同的天气条件下。然后，一种新颖的分段线性预测方法

[32] 主张用正态混合模型来表示多时相高光谱图像，并使线性预测模型能够区分背景子空间。以及基于自编码器的高光谱异常变化检测（ACDA）

[33] 提出通过具有多个结构层的自动编码器在多时相光谱向量之间建立有效的非线性映射关系。结果发现，这些方法在检测异常变化时过度强调光谱信息而忽略了空间信息。

B. 高光谱二值变化检测

对于高光谱遥感 (HBCD) 而言, 高光谱遥感的一个关键问题是如何充分利用详细的光谱信息, 其中涉及两个子问题, 包括冗余相邻光谱信息的细化以及探索丰富的光谱特征以区分变化和伪变化。传统方法大致可以分为三类[34]、[35], 其中基于代数的方法计算多时相高光谱遥感之间的光谱差异, 基于变换的方法比较新特征空间的变换信息, 基于分类的算法通过比较多时相高光谱遥感的分类图来获得变化检测结果。侯等人[36]设计了一种创新的方法, 通过多个形态学剖面充分利用高光谱遥感的空间信息, 并提出了有效的属性剖面策略来提取变化信息。侯等人[37]提出了一种新颖的三阶塔克分解, 以有效利用光谱和空间信息, 旨在抑制未变化的差异并放大变化的差异。研究人员已尝试使用深度神经网络来解决高光谱图像分类问题[38]、[39]。通用端到端二维卷积神经网络 (GETNET) [40]开发了一个端到端二维卷积神经网络框架, 其中设计的混合亲和矩阵与丰裕图相结合, 有助于充分利用高光谱图像的光谱信息。针对高光谱图像分类问题, 提出了一种基于自编码器和对抗学习的无监督频谱映射新方法[41], 该方法利用频谱特征并最小化输入频谱向量的重建损失。李等人[42]提出了一种新颖的策略, 将两种无监督模型驱动方法结合起来, 为提出的二维高光谱图像变化检测 (CD) 框架生成可靠的伪标签。并且针对高光谱图像分类问题, 已经开发了几种基于注意力的方法, 以从大容量的高光谱图像数据中增强最具信息性的空间和频谱特征。提出了一种多级编码器-解码器注意力网络 (ML-EDAN [19]), 利用设计的上下文信息引导注意力模块提取分层特征。SSA-SiamNet [43] 旨在强调有判别力的通道和位置, 并抑制信息量较少的通道和位置。然而, 基于深度学习的这种方法主要由有标注的样本驱动, 在实际应用中会受到样本昂贵甚至无样本的困扰。因此, 如何在没有标签或粗粒度标签的高分辨率遥感 (HSI) 数据中充分探索空间和频谱信息, 已成为当前的研究重点[44]、[45]。

C. 自监督学习

自监督特征学习是一种在无标签数据上的强大特征学习方法[20]、[21]、[23]、[46], 并且在视觉图像处理方面取得了巨大成功, 例如图像分类[47]、视频表示学习[48]和目标识别[49]。一般来说, 自监督学习通过前缀任务生成大量有标签数据, 然后从自生成的有标签数据中学习特征表示[50]、[51]。而对比学习 (CL) 是一种有判别

性的自监督学习方法, 旨在吸引正样本对并排斥负样本对。数据增强是生成大量正负样本的常见方法之一。单个图像及其增强视图形成一对正样本, 而一对负样本是指不同图像的增强视图。具体来说, 随机水平翻转、垂直翻转、随机裁剪和调整大小、旋转以及噪声是重要且有用的数据变换算子。并且已经开发了大量基于孪生网络的新方法来驱动特征表示学习。动量对比 (MoCo) [52]构建了一个大型字典查找表以促进对比特征学习。用于视觉表示对比学习的简单框架 (SimCLR) [53]在一个批次中使用大量的负样本, 以平衡特征对齐以及嵌入到特征空间中的样本的均匀性。自举自己的潜在 (BYOL) [54]直接去除负样本, 并通过训练在线网络来预测目标网络的视图, 其中目标网络通过在线网络的缓慢移动平均进行更新。简单孪生网络 (SimSiam) [55]在停止梯度约束下, 最大化一个增强视图的预测目标与来自编码器的另一个视图的嵌入向量之间的相似度。

CL 的流行引发了基于 SSL 的先进遥感图像变化检测方法的发展[25]、[26]。目前, CL 也已应用于多光谱光学和 SAR 遥感变化检测。在变化较小的先验概率下, 双时相遥感图像被视为在同一地点不同时间获取的同一图像的不同视图。双时相图像同一位置的图像块被视为正样本对, 而同一训练批次大小的不同位置的图像块被视为负样本对。在没有任何标签的情况下, 网络能够通过最小化正样本嵌入特征向量的距离并拉开负样本嵌入特征向量来学习输入的特征表示。一般来说, 为避免网络崩溃, 需要较大的批次大小来满足每批有足够的负样本。

在高光谱变化检测中, 由于空间和频谱信息的次优开发以及训练样本数量少且有限, 所提出的方法深受当前自监督学习的启发。我们提出了一种新颖的自监督空谱高光谱理解网络, 以实现准确的变化检测。所提出的方法从二维成像空间和频谱维度的角度精确处理高光谱图像, 挖掘深层有效的空间和频谱特征。由于没有负样本对, 所提出的 HyperNet 仅使用正样本对进行相似性比较。而且 HyperNet 不需要大的训练批次大小, 提高了 HyperNet 的实用性。与基于补丁的样本对不同, 整个图像被输入到 HyperNet 中, 以获取全局信息比较和用于变化检测的逐像素特征。

III. 方法论

本节详细介绍了所提出的方法 HyperNet。图 1 展示了 HyperNet 的流程图。




图 1. 用于高光谱变化检测的所提出的超网络的结构：(a) 是 SSA 模块，其专门设计用于充分挖掘高光谱图像（HSI）丰富的信息，包括 RSABs、RCABs 和融合模块；(b) 是投影器，用于提高非线性特征映射能力；(c) 是预测器，仅组装在超网络的其中一个分支上，并与其他分支交换以交替最小化相似性损失。

对于高光谱变化检测，它主要由三个部分组成：1) SSA 模块；2) 投影器；3) 预测器。整个双时相高光谱图像首先通过 SSA 模块进行处理，旨在充分挖掘空间关系和多样化的光谱信息。投影器进一步将提取的特征嵌入映射，以获取更深层次和更丰富的特征。而仅配备单个分支的预测器为另一个分支创建预测目标。自监督训练的目标是迫使一个视图的投影嵌入与所选掩码区域上另一个视图的预测目标尽可能相似。在没有标记数据的情况下，预检测策略提供了一个粗略的伪标签作为补充。设计了一种新颖的焦点余弦相似度损失来增强那些困难样本的贡献，以实现更好的训练。HyperNet 的两个分支共享相同的权重，致力于在没有劳动成本标签的情况下学习双时相高光谱图像的对齐特征，然后使用所学习特征的距离图轻松地未变化区域与变化区域分离。

A. SSA 模块

SSA 模块被精心设计为分别关注空间和频谱特征。空间注意力分支专注于从局部和全局尺度获取空间关系，而频谱注意力分支有助于探索有用且有信息价值的频谱特征。然后，空间和频谱特征被自适应地融合在一起，以获取每个像素的有利信息。

1) 空间注意力分支：空间注意力分支由三个有效的构建模块组成，即专门为空间特征表示设计的残差空间注意力块（RSAB）。RSAB 的详细架构如图 2(a)所示。以 HSI $\mathbf{X} \in \mathbb{R}^{H \times W \times C}$ 作为输入为例，先经过 3×3 二维卷积层，随后是批量归一化（BN）层；首先，在小初始场内提取浅边缘和线条信息。




图 2. 架构：(a) RSAB；(b) RCAB；(c) 自适应特征融合模块；(d) CA；以及 (e) SA。

输出可以表示为 $\mathbf{X}^{(1)} \in \mathbb{R}^{H \times W \times n}$ （以下等式），其中 n 指的是特征图的数量：

$$\mathbf{X}^{(1)} = \text{BN}(f^{3 \times 3}(\mathbf{X})). \quad (1)$$

为了专注于最具信息特征，在卷积之后引入了卷积块注意力模块（CBAM）[56]。CBAM 分别包含通道注意力（CA）[如图2(c)所示]和空间注意力（SA）[如图2(d)所示]。CA 压缩空间信息，并从数百个频谱波段中激发最具判别性的频谱信息。具体来说，全局平均和最大池化将空间图的每个通道转换为一个具有代表性的统计值。然后，另外两个共享的 1×1 二维卷积层旨在获得受启发的通道表示。提取的通道特征之和通过 sigmoid 激活函数 σ 转换为介于 0 到 1 之间的通道注意力图 $\mathbf{M}_{\text{ca}}$ 。CA 的数学定义如下：

$$\mathbf{M}_{\text{ca}} = \sigma \left(f^{1 \times 1} \left(f^{1 \times 1} (\text{AvgPool}(\mathbf{X}^{(1)})) + f^{1 \times 1} \left(f^{1 \times 1} (\text{MaxPool}(\mathbf{X}^{(1)})) \right) \right) \right) \quad (2)$$

其中，权重越大，输入特征的光谱信息就越有吸引力。通过元素乘法 $\otimes$ 获得激励通道注意力特征 $\mathbf{F}_{\text{ca}}$ ，其可以表示为公式

$$\mathbf{F}_{\text{ca}} = \mathbf{M}_{\text{ca}} \otimes \mathbf{X}^{(1)}. \quad (3)$$

类似地，如图 2(d)所示，SA 首先减少通道数，然后专注于如何利用最有信息的空间信息。SA 的最大池化层和平均池化层分别专注于边缘和纹理信息。从这两个池化层提取的特征通过一个核滤波器大小为 7×7 的二维卷积层进行进一步变换。然后，sigmoid 激活函数将特征转换为 0 到 1 的范围，以获得权重约束图。

$\mathbf{M}_{sa}$, 它最终与输入特征相乘以得到输出 $\mathbf{F}_{sa}$

$$\mathbf{M}_{sa} = \sigma(f^{7 \times 7}([\text{AvgPool}(\mathbf{F}_{ca}); \text{MaxPool}(\mathbf{F}_{ca})])) \quad (4)$$

$$\mathbf{F}_{sa} = \mathbf{M}_{sa} \otimes \mathbf{F}_{ca}. \quad (5)$$

值得注意的是, 正是这种门控机制控制着信息的量。在权重更接近 1 的位置, 空间信息得到强调, 而在权重更接近 0 的区域, 空间信息则受到抑制。

此外, 空间注意力块采用残差架构[57]设计, 以避免过拟合并方便融合深层和浅层特征。这里的输入特征为 $\mathbf{X} \in \mathbb{R}^{H \times W \times C}$, 空间注意力的输出特征为 $\mathbf{F}_{sa} \in \mathbb{R}^{H \times W \times n}$ 。当输入通道不等于输出通道时, 对输入进行下采样是必要的。具体来说, 对输入执行 1×1 二维卷积层和批量归一化(BN)以得到 $\mathbf{X}_d \in \mathbb{R}^{H \times W \times n}$ 。因此, 第一个 RSAB 的残差输出描述为 $\mathbf{X}_{RSAB}^{(1)} \in \mathbb{R}^{H \times W \times n}$ 。

$$\mathbf{X}_d = \text{BN}(f^{1 \times 1}(\mathbf{X})) \quad (6)$$

$$\mathbf{X}_{RSAB}^{(1)} = \text{ReLU}(\mathbf{X}_d + \mathbf{F}_{sa}). \quad (7)$$

需要注意的是, 对于每个 RSAB, 输出特征图的通道数被设定为 n 。因此, 只有第一个 RSAB 配备了下采样。

2) 频谱注意力分支: 对于频谱注意力分支, 专门设计了三个残差通道注意力块(RCABs)用于频谱特征表示。如图2(b)所示, 以HSI $\mathbf{X} \in \mathbb{R}^{H \times W \times C}$ 作为输入为例, 选择大小为 1×1 的二维卷积层来集中频谱空间。另一个BN层用于提高网络的泛化能力。输出特征图 $\mathbf{X}^{(2)} \in \mathbb{R}^{H \times W \times n}$, 其中 n 为设定的数量, 可以表示为

$$\mathbf{X}^{(2)} = \text{BN}(f^{1 \times 1}(\mathbf{X})). \quad (8)$$

RCAB 由 CA 组装而成, CA 经过裁剪以强调最有用的频谱带, 并获得从 0 到 1 的频谱注意力图 $\mathbf{M}_{ca}$ 。其定义为

$$\mathbf{M}'_{ca} = \sigma(f^{1 \times 1}(f^{1 \times 1}(\text{AvgPool}(\mathbf{X}^{(2)})) + f^{1 \times 1}(f^{1 \times 1}(\text{MaxPool}(\mathbf{X}^{(2)})))). \quad (9)$$

对于 RCAB 而言, 当输入和输出加权频谱特征大小相同时, 会建立快捷连接。因此, 第一个 RCAB 的输出正是加权通道注意力特征, 其通过以下公式获得。并且我们将 RCAB 获取的所有特征图的数量设为 n 。

$$\mathbf{X}_{RCAB}^{(1)} = \mathbf{M}'_{ca} \otimes \mathbf{X}^{(2)}. \quad (10)$$

与那些仅设计一个分支同时提取空间和频谱信息的方法相比, 针对高维高光谱立方体, 我们分别精心设计了两个分支, 分别专注于空间和频谱信息。空间注意力分支堆叠了三个 RSAB 以提取高级语义特征, 而




图 3. (a) 投影仪和 (b) 预测器的架构。

频谱注意力分支结合可重用注意力模块(RCABs)以提取有判别性的频谱特征。空间注意力分支和频谱注意力分支是两个独立的分支, 并分别进行升级。

3) 自适应特征融合模块: 在获取高级空间特征 $\mathbf{X}_{RSAB}^{(3)}$ 并且频谱特征 $\mathbf{X}_{RCAB}^{(3)}$,

一个自适应空频特征融合模块被定制以获取融合特征。如图2(c)所示, 我们采用 1×1 二维卷积层和BN来处理提取的空间特征, 采用 3×3 二维卷积层和BN来处理频谱特征。通过自适应融合模块, 空间特征得到了进一步增强, 频谱特征得到了聚合。并且这两个重新组织的特征沿着通道轴连接在一起, 得到最终融合特征 $\mathbf{X}_{fuse} \in \mathbb{R}^{H \times W \times (2n)}$, 其可以描述如下:

$$\mathbf{X}_{fuse} = [\text{BN}(f^{1 \times 1}(\mathbf{X}_{RSAB}^{(3)})); \text{BN}(f^{3 \times 3}(\mathbf{X}_{RCAB}^{(3)}))]. \quad (11)$$

B. 暹罗投影仪和预测仪

投影器旨在提升提取的空间和频谱特征, 以获得更深的嵌入向量。如图3(a)所示, 投影器由三个密集的 1×1 卷积层组成, 并配有BN层和修正线性单元(ReLU)激活函数。请注意, 这三个二维卷积层的输出通道数相同, 均为 $2n$ 。

具有停止梯度操作的预测器是自监督训练的关键部分。只有HyperNet的一个分支配备了预测器。尽管HyperNet学习提取双时相高光谱图像的对齐特征, 但它可能会引入相同但无意义的特征, 以迫使整个孪生网络产生的输出特征相似。如图1所示, 第一分支中标记为 $\mathbf{P}_1$ 的预测器的输出特征被迫与第二分支中投影器的输出特征 $\mathbf{Z}_2$ 相似。同时, 在第二分支中不进行梯度反向传播, 只有高光谱图像 $\mathbf{X}$ 负责梯度反向传播。同样, 第一分支中投影器 $\mathbf{Z}_1$ 的输出特征和第二分支中预测器的输出特征 $\mathbf{P}_2$ 被迫相似, 其中

梯度传播在第一分支中停止。从预测器获得的特征可能与从投影器获得的特征不同。但相似性约束和交换策略有助于特征相互之间交替地更加相似，使超网络能够从双时相高光谱图像中学习到有意义的对齐空间-频谱特征。

图 3(b) 展示了预测器的结构，它由两个密集的 1×1 卷积层以及带有批量归一化 (BN) 和 ReLU 层组成。具体而言，第一个卷积层输出通道数为 n 的压缩特征图。而最终的卷积层输出通道数为 $2n$ 的扩展特征图。投影器和预测器共享相同的输出特征图大小。

C. 焦点余弦损失函数

余弦相似度距离是用于比较两个高维向量相似度的一种常用度量指标。两个向量越相似，余弦相似度距离值越接近 1。而差异较大的双时相向量的相似度值接近 0 甚至 -1。自然成像条件可能导致大面积区域出现不同的光谱值。然而，未变化区域的大部分光谱差异易于优化。换句话说，这些正样本易于被拉拢。因此，在训练过程中，绝大多数容易样本占主导地位，而困难样本更难优化。为了解决容易样本主导的问题，提出了一种新颖的相似度损失函数，名为焦点余弦。

给定从第一视图的嵌入空间获得的 $\mathbf{Z}_1 \in \mathbb{R}^{H \times W \times (2n)}$ 以及从其他视图的预测目标获得的 $\mathbf{P}_2 \in \mathbb{R}^{H \times W \times (2n)}$ ，所提出的名为焦点余弦 L_{fc} 的损失函数定义如下：

$$\mathcal{L}_{fc}(\mathbf{Z}_1, \mathbf{P}_2) = -(2 - \cos(\mathbf{Z}_1, \mathbf{P}_2)) \otimes \cos(\mathbf{Z}_1, \mathbf{P}_2) \quad (12)$$

$$\cos(\mathbf{Z}_1, \mathbf{P}_2) = \frac{\mathbf{Z}_1}{\|\mathbf{Z}_1\|_2} \cdot \frac{\mathbf{P}_2}{\|\mathbf{P}_2\|_2} \quad (13)$$

在这里，我们将 $(2 - \cos(\mathbf{Z}_1, \mathbf{P}_2))$ 作为调整因子。对于困难样本， $\cos(\mathbf{Z}_1, \mathbf{P}_2) \rightarrow -1$ ，那么 $(2 - \cos(\mathbf{Z}_1, \mathbf{P}_2)) \rightarrow 3$ 。在这种情况下，焦点余弦损失函数大大增加了困难样本的权重。对于容易样本， $\cos(\mathbf{Z}_1, \mathbf{P}_2) \rightarrow 1$ ， $(2 - \cos(\mathbf{Z}_1, \mathbf{P}_2)) \rightarrow 1$ 。结果，容易样本的权重保持不变。如图 4 所示，蓝色线表示原始的余弦相似度损失函数，红线表示所提出的焦点余弦损失函数。对于用蓝色表示的原始损失函数，当两个向量足够相似且夹角为零时，损失达到最小值。所提出的焦点余弦损失函数与余弦相似度损失函数具有相同的最小值。此外，当两个向量夹角较大，显然是一对困难的正样本时，这两个向量的焦点余弦损失与原始余弦相似度损失相比大幅上升到非常高的值。当两个向量夹角较小时，更像是容易的正样本，这两个向量的焦点余弦损失下降，低于原始余弦相似度损失函数所得的值。




图 4. 蓝色为余弦相似度损失函数的比较，红色为所提出的焦点余弦损失函数的比较。

考虑到多时相高光谱图像之间可能会发生广泛的变化，为所有像素计算相似性损失会极大地妨碍网络的性能。我们提出了一种预检测策略来获取一个伪掩码 $\mathbf{g}$ ，其中从某种经典方法的预检测结果中选择数量有限的具有高概率不变动的像素。

最终的目标函数被定义为 L 。

$$\mathcal{L} = \frac{1}{2} \cdot \mathbf{g} \otimes (\mathcal{L}_{fc}(\text{StopGrad}(\mathbf{Z}_1), \mathbf{P}_2) + \mathcal{L}_{fc}(\text{StopGrad}(\mathbf{Z}_2), \mathbf{P}_1)). \quad (14)$$

通过使用梯度反向传播最小化损失函数来升级整个网络的参数。所提出的超网络能够从双时相高光谱图像中学习强大的像素级深层特征。此外，对于那些未改变的区域，双时相特征在特征空间中相互对齐，而对于改变的区域则分散。因此，SSA 模块学习到的特征非常适合将未改变的与改变的区分开来。对于后处理，使用 Diff-RX [58] 作为异常检测器来检测三个 HBCD 数据集集中的异常变化。并且采用余弦相似度距离与 K 均值 [59] 相结合，用于二值变化图的阈值处理。

IV. 实验与分析

为了测试所提出的方法在高光谱变化检测方面的有效性，已经在 HACD 任务和 HBCD 上进行了大量的高光谱实验。在本节中，首先介绍数据集的描述。接下来，给出实验设置的细节。然后，分别展示在 HACD 任务和 HBCD 上测试实验结果的分析。

A. 高光谱数据集

用于 HACD 任务的数据集包括基准数据集“Viareggio 2013” [60] 以及另一个模拟的 Hymap 数据集。

B. “比利亚雷焦 2013”数据集

总的来说，“比利亚雷焦 2013”数据集包含三个高分辨率图像 (HSI)，即 D1F12H1、D1F12H2 和 D2F22H2，如图 5 所示。这三个高分辨率图像均拍摄于意大利的比利亚雷焦。




图 5. (从左至右) HACD 任务的“维耶里耶 2013”数据集的伪彩色表示: (a) “维耶里耶 2013”数据集的 D1F12H1; (b) D1F12H2; (c) D2F22H2; (d) 示例 1 的参考图: D1F12H1 - D1F12H2; (e) 示例 2 的参考图: D1F12H1 - D2F22H2。




图 6. 用于 HACD 任务的模拟 Hymap 数据集的伪彩色图: (a) 原始 Hymap 图像; (b) 模拟的 Hymap 图像; (c) 参考图; 以及 (d) 通过低通滤波器处理的随机均匀分布的模拟噪声图。

通过机载高光谱传感器 SIM.GA 获取。光谱信息覆盖从 400 到 1000 纳米范围的光谱, 光谱分辨率约为 1.2 纳米。空间分辨率为 0.6 米。图像尺寸均为 450×375 , 有 127 个波段。数据经过去条带处理[61]和光谱分箱处理, 可在 <http://rsipg.dii.unipi.it/> 上获取。D1F12H1 和 D1F12H2 于 2013 年 5 月 8 日同一天获取, 构成 EX-1: D1F12H1 - D1F12H2。而 EX-2: D1F12H1 - D2F22H2 由 D1F12H1 和 D2F22H2 组成, 后者于 2013 年 5 月 9 日获取。EX-1 的两个高光谱图像具有非常相似的成像条件, 异常变化主要来自车辆的运动。但 EX-2 的情况则截然不同。对于 EX-2, 拍摄平台的姿态存在严重偏移, 造成广泛的失真, 给逐像素异常变化检测带来巨大挑战。此外, D2F22H2 的天气状况也与 D1F12H1 有所不同, 树木和建筑物周围出现了阴影。

1) 模拟的 Hymap 数据集: 模拟的 Hymap 数据集 (如图 6 所示) 旨在测试噪声对所提出方法的影响; 第一张图像是在美国蒙大拿州库克市于 2006 年 7 月 4 日获取的高光谱目标检测数据集。可在 <http://dirsapps.cis.rit.edu/blindtest/> 上获取。图像尺寸为 $280 \times 800 \times 126$ 。光谱范围从 453 到 2486 纳米。为了模拟不同的成像条件, 首先创建了一个从 -10 到 10 随机均匀分布的噪声图, 然后用标准偏差为十个像素的低通滤波器进行处理。模拟的高光谱图像是通过将噪声图与原始的 Hymap 数据相加创建的。此外, 还有一个偏移量




图 7. (从上到下) HBCD 的赫米斯顿数据集、贝伊数据集和圣巴巴拉数据集的伪彩色图: (a) 在时间 1 获取的高分辨率遥感图像; (b) 在时间 2 获取的高分辨率遥感图像; (c) 参考图。

在模拟的高分辨率遥感图像 (HSI) 上应用水平和垂直方向的像素。通过在其他位置替换物体来获得异常变化。

此外, 我们还对另外三个 HBCD 数据集测试了 HyperNet 的有效性。

a) 赫米斯顿数据集: 如图 7 第一行所示, 分别于 2004 年 5 月 1 日和 2007 年 5 月 8 日, 在美国俄勒冈州赫米斯顿通过赫皮翁获取了两幅高光谱图像。图 7(c) 展示了高光谱遥感图像分类 (HBCD) 的参考图。该场景涵盖了广泛的灌溉农田、河流和耕地, 大小为 307×241 像素, 包含 154 个光谱波段。

b) 贝伊数据集: 图 7 的第二行给出了贝伊数据集的三维伪彩色立方体表示, 这些数据分别于 2013 年和 2015 年获取, 使用 AVIRIS 传感器环绕美国加利福尼亚州帕特森市。贝伊数据集主要由农田和建筑物覆盖, 空间大小为 600×500 像素, 有 224 个光谱波段。请注意, 仅采用有标记的变化区域和不变化区域进行评估。

c) 圣巴巴拉数据集: 作为高分辨率遥感图像分类 (HBCD) 的最后一个示例, 如图 7 的第三行所示, 其中 (a) 和 (b) 分别于 2013 年和 2014 年在圣巴巴拉地区使用 AVIRIS 传感器拍摄。空间维度为 984×740 像素, 且两者均有 224 个光谱波段。这两个高光谱图像记录了城市演变和农田的动态变化, HBCD 为检测城市发展的准确动态变化提供了一个强大的工具。

C. 实施细节

1) 实验设置: 我们使用 Pytorch 实现了我们的方法, 并在单个 NVIDIA RTX 3090 GPU 上进行实验。网络的参数通过 He-normal 方式初始化[62]。优化器是随机梯度下降 (SGD), 动量为 0.9, L2 正则化效率为 0.0001。我们将初始学习率设置为

表一 从六个数据集的预检测结果中选择样本

Dataset	Image size	Selected numbers	Ratio (%)	n
D1F12H1-D1F12H2	450*375	8192	4.85	64
D1F12H1-D2F22H2	450*375	8192	4.85	64
Simulated Hymap	280*800	8192	3.66	64
Hermiston	307*241	8192	11.07	72
Bay	600*500	8192	2.73	112
Santa Barbara	492*740	8192*2	4.50	112

0.05, 并采用余弦衰减[63]策略。训练的总轮数设定为200。由于所提出的方法是一种全卷积神经网络, 无需批量大小即可将整个图像输入到网络中。对于预检测策略, 对于HACD任务选择Diff-RX作为预检测方法, 对于HBCD选择变化矢量分析(CVA)。从预检测结果中选择伪样本。所有数据集选择的伪样本数量列于表I中。请注意, 由于Hyper-Net的尺寸为 984×740 较大, Santa Barbara数据集被分割成两个。特征数 n 的参数设置总结于表I中。

2) 比较方法: 为了验证超网络的有效性, 选择了几种比较方法。对于HACD任务, 另外选择了八种方法, 即CC [31]、无监督慢特征分析(USFA) [64]、Diff-RX [58]、双曲异常变化检测器(HACD) [11]、简单差值双曲异常变化检测器(SDHACD) [11]、简单差值异常变化检测器(SDACD) [11]、多时相空间: 用于高光谱异常变化检测的频谱比较网络(MTC-NET) (patch = 13) 和 MTC-NET (patch = 31) [65]。为了强调补丁大小对变化检测性能的影响, 选择了补丁大小设置为 13×13 的MTC-NET (patch = 13) 和补丁大小设置为 31×31 的MTC-NET (patch = 31) 进行比较。对于HBCD, 另外选择了六种算法, 即CVA、迭代慢特征分析(ISFA) [66]、自监督多传感器变化检测(MSCD) [26]、多视图遥感图像中的自监督变化检测(OSCD) [25]、MTC-NET (patch = 13) 和 MTC-NET (patch = 31) 进行比较。值得注意的是, OSCD和MSCD是两种基于补丁的用于多传感器变化检测的SSL方法, 后者已在多光谱图像变化检测中进行了测试。根据[26], MSCD的批量大小设定为64, 而OSCD对于Bay和Santa Barbara数据集采用补丁大小为16, 对于Hermiston数据集采用补丁大小为8。除了OSCD之外, 其余对比的深度学习方法都将批量大小设定为256。OSCD采用简单批次中一个正样本和另外 $N-1$ 个负样本的多视图对比损失, 其中批次大小设定为 N 。因此, OSCD的批次大小设定为1024。各种方法的参数设置细节见表二。

3) 评估标准: 此外, 计算受试者工作特征(ROC)和曲线下面积(AUC)以定量评估HACD任务, 同时计算总体准确率(OA)、Kappa值、F1分数、精度和召回率

表二

针对HACD任务和HBCD的各种方法的参数设置

Method	Batch size	Patch size	Stride
MSCD	256	64	32
OSCD	1024	16	8
MTC-NET (patch size=13)	256	13	13
MTC-NET (patch size=31)	256	31	31




图8. EX-1的异常变化检测图: D1F12H1-D1F12H2在: (a) CC上; (b) USFA上; (c) Diff-RX上; (d) HACD上; (e) SDHACD上; (f) SDACD上; (g) MTC-NET (补丁=13)上; (h) MTC-NET (补丁=31)上; (i) 所提出的超网络上; 以及 (j) 参考变化图上。

是为六溴环十二烷(HBCD)的定量评估而计算的。检测图被分割成四个部分, 即真阳性(TP)、真阴性(TN)、假阴性(FN)和假阳性(FP)。

D. HACD任务结果

图8展示了八种对比方法和所提出的超网络在EX-1: D1F12H1-D1F12H2上的异常变化检测结果。检测图越暗, 该区域越有可能是未变化的, 反之亦然。可以发现, USFA、SDHACD、MTC-NET (patch = 31) 和所提出的超网络的背景几乎为黑色, 表明在背景压缩方面表现良好。然而, 对于MTC-NET (patch = 31), 较大的输入补丁大小导致信息共享范围广泛以及位置精度的降低。结果, MTC-NET (patch = 31) 的检测图中存在一些异常变化的遗漏。尽管较小的输入补丁大小减少了这些影响, 但MTC-NET (patch = 13) 的检测图中出现了更多的噪声。基于全卷积神经网络, 所提出的超网络通过设计空间和频谱注意力模块平衡了对空间信息和位置精度的需求, 其中整合了局部空间信息、像素级频谱信息以及来自全局尺度的注意力。如图8(i)所示, 在HyperNet的检测图中, 异常变化几乎凸显出来, 变化区域的边缘得以保留。

图9展示了在EX-2: D1F12H1-D2F22H2上所有方法的异常检测图。由于传感器的剧烈移动, 在边缘可以观察到明显的亮度。




图 9. EX-2: D1F12H1-D2F22H2 的异常变化检测图: (a) CC; (b) USFA; (c) Diff_RX; (d) HACD; (e) SDHACD; (f) SDACD; (g) MTC-NET (补丁 = 13); (h) MTC-NET (补丁 = 31); (i) 所提出的超网络; 以及 (j) 参考变化图。

在所有结果中, 松树区域从右上角延伸至左中。USFA、HACD 和所提出的超网络的绝大多数背景结果值较低, 在降低普遍频谱差异的影响方面表现出色。在 MTC-NET (patch = 13) 和 MTC-NET (patch = 31) 的结果中可以观察到大量噪声。对于 EX-2, 异常变化主要源于车辆的出现和消失, 并且集中在右中心, 这是一个停车场。与参考变化图相比, HACD、SDHACD 和超网络能够检测到几乎所有的异常变化, 其中超网络的结果的异常变化值似乎比其他结果更亮。与 MTC-NET (patch = 13) 和 MTC-NET (patch = 31) 的图相比, 超网络的结果在变化区域没有锐边扩展, 遗漏和噪声更少, 表明所提出的像素级超网络性能更好。双分支 SSA 模块分别专注于频谱和空间信息, 从两个不同维度提取了足够的特征。

在模拟的 Hymap 数据集上, 所有方法的异常变化检测结果如图 10 所示。由于在水平和垂直方向上的偏移, 图像中心 (这是一个建筑物、车辆和道路的密集混合区域) 存在大量错位。除了 HACD 之外, 所有方法在中心区域都获得了密集的高值。此外, 噪声对异常变化的检测也有负面影响。除了 USFA 之外, 在所有对比方法的检测图中都可以发现明显的噪声斑点。而且, 在 MTC-NET (patch = 31) 的检测图中, 噪声的影响尤其被放大。然而, 噪声对 HyperNet 的检测结果影响较小, 表明所提出的方法具有很强的抗噪能力。此外, HyperNet 检测到了大多数模拟的异常变化, 在异常变化检测方面表现良好。

还提供了定量评估以测试所提出方法的有效性。图 11 的第一列展示了所有方法在三个数据集上的 ROC 曲线, 其中横轴表示误报率, 纵轴




图 10. 模拟的 Hymap 数据集在以下方面的异常变化检测图: (a) CC; (b) USFA; (c) Diff_RX; (d) HACD; (e) SDHACD; (f) SDACD; (g) MTC-NET (补丁 = 13); (h) MTC-NET (补丁 = 31); (i) 所提出的超网络; 以及 (j) 参考变化图。

轴分别表示检测的概率。在低误报率下获得高检测概率的方法是一种出色的异常变化检测器。在所有三个数据集上, 所提出的超网络的 ROC 曲线 (红色) 都超过了其他对比方法。紫色所示的 MTC-NET (patch = 13) 在 EX-1: D1F12H1-D1F12H2 和模拟的 Hymap 数据集上表现良好; 浅绿色的 HACD 在 EX-1: D1F12H1-D2F22H2 和 EX-2: D1F12H1-D2F22H2 上也取得了相当的成效。

图11的第二列是所有方法在三个数据集上的可分离性图。分别收集异常变化和背景的输出值, 以测试分离异常变化和背景的能力。为了便于可视化, 将值归一化为[0,1]。橙色框表示异常变化, 绿色框表示背景。每个框的顶部和底部分别表示最大值和最小值, 框的主要部分包含从最小25%到最大75%的值。对于EX-1: D1F12H1-D1F12H2, USFA、SDHACD和MTC-NET (patch = 31) 可以抑制低范围的背景值, 但它们与异常变化值的可分离性较差。CC、Diff-RX、HACD和SDACD的异常变化框和背景框之间有很大的重叠。相比之下, MTC-NET (patch = 13) 和HyperNet在相应的框中获得了较大的间隙, 其中HyperNet的背景值落入较低的范围。EX-2: D1F12H1-D2F22H2的情况与EX-1非常相似。然而, MTC-NET (patch = 13) 和 MTC-NET (patch = 31) 都




图 11. 第一列是所有方法在以下数据集上的 ROC 曲线: (a) 示例 1: D1F12H1 - D1F12H2; (c) 示例 2: D1F12H1 - D2F22H2; 以及 (e) 模拟的 Hymap 数据集, 第二列是所有方法在以下数据集上的可行性图: (b) 示例 1: D1F12H1 - D1F12H2; (d) 示例 2: D1F12H1 - D2F22H2; 以及 (f) 模拟的 Hymap 数据集。

获取较大的背景值, 其在一定程度上与相应的异常变化值相交。HyperNet 在异常变化框和背景框之间获得了良好的可分离性。对于模拟的 Hymap 数据集, HyperNet 的结果显示异常变化与背景之间存在较大距离。观察到 USFA 和 Diff-RX 的结果具有较低的异常变化值, 但它们与异常变化值的交集很大程度。此外, HACD 的可分离性较低, 导致 ROC 曲线下降如图 11(e)所示。尽管这是一个模拟数据集, 但经过低通滤波处理的随机均匀分布噪声以及整个图像上的偏移对异常变化检测构成了巨大挑战。HyperNet 表现良好, 能够区分异常变化与复杂背景。表 III 给出了所有方法在三个数据集上的 AUC 性能比较。AUC 表示 ROC 值下的面积, 是异常变化检测器的综合指标。最高的用粗体表示, 第二好的用下划线表示。对于所有三个数据集, HyperNet 都优于其他方法, EX-1 的最佳 AUC 为 0.9147, EX-2 为 0.9126, Hymap 数据集为 0.9927, 这远高于第二高值。HACD 排名第二, EX-1: D1F12H1-D1F12H2 的 AUC 为 0.8489, EX-2: D1F12H1-D2F22H2 的 AUC 为 0.8666。MTC-NET (patch = 13) 获得了

表三

在三个 HACD 任务数据集上对所有方法的 AUC 比较

Method	EX-1	EX-2	Simulated Hymap
CC	0.6991	0.7196	0.8327
USFA	0.8220	0.8479	0.8437
Diff-RX	0.7993	0.8277	0.8249
HACD	<u>0.8489</u>	<u>0.8666</u>	0.7232
SDHACD	0.7978	0.8525	0.8343
SDACD	0.7372	0.7896	0.8069
MTC-NET (patch=13)	0.8346	0.8019	0.9589
MTC-NET (patch=31)	0.7776	0.8411	0.9276
HyperNet	0.9147	0.9126	0.9927




图 12. 赫米斯顿数据集上的二值变化检测图: (a) CVA; (b) ISFA; (c) MSCD; (d) OSCD; (e) MTC-NET (补丁 = 13); (f) MTC-NET (补丁 = 31); (g) 所提出的超网络; 以及 (h) 参考变化图。

表四

在赫米斯顿数据集上对所有方法进行定量评估

Method	OA	Kappa	F1	Precision	Recall
CVA	0.9272	0.7670	<u>0.8103</u>	<u>0.9819</u>	0.6898
ISFA	0.9023	0.6716	0.7262	0.9852	0.5750
MSCD	0.7851	0.4788	0.6201	0.5154	<u>0.7782</u>
OSCD	0.4332	0.1307	0.4344	0.2802	0.9656
MTC-NET (patch size=13)	0.7960	0.4741	0.6011	0.6111	0.6581
MTC-NET (patch size=31)	0.8343	0.5399	0.6468	0.6370	0.6733
HyperNet	<u>0.9206</u>	<u>0.7613</u>	0.8112	0.8740	0.7569

对于模拟的 Hymap 数据集, 排名第二, 其曲线下面积 (AUC) 等于 0.9589。

E. 六溴环己烷(HBCD)检测结果

在赫米斯顿数据集上, 所有对比方法和所提出的超网络的二进制变化检测结果如图 12 所示。具体而言, 真阳性 (TP) 用白色表示; 真阴性 (TN) 用黑色表示; 假阳性 (FP) 用红色表示, 假阴性 (FN) 用绿色表示。存在大量的




图 13. 在 Bay 数据集上的二值变化检测图: (a) CVA; (b) ISFA; (c) MSCD; (d) OSCD; (e) MTC-NET (补丁 = 13); (f) MTC-NET (补丁 = 31); (g) 所提出的超网络; 以及 (h) 参考变化图。

在 OSCD 的检测图[图 12(d)]中, 红色标记为错误的检测, 这与表四中呈现的低精度 0.2802 一致。分析表明, OSCD 的训练需要较大的批量大小, 而 Hermiston 数据集是一个小规模的数据集, 尺寸为 307×241 。在 MSCD、MTC-NET (patch = 13) 和 MTC-NET (patch = 31) 的结果中也有些红色的错误检测, 特别是在左下角, 那里有一些建筑物。在 CVA 和 ISFA 的结果中可以发现一些绿色的漏检。相比之下, HyperNet 能够检测到大多数变化, 且错误检测很少。表四列出了所有方法在 Hermiston 数据集上的定量评估。最大值以粗体显示, 第二大值以下划线显示。CVA 分别获得了最佳的整体精度 (OA) 和 Kappa 值, 分别为 0.9272 和 0.7670。HyperNet 获得了相当的 OA 值为 0.9206 和 Kappa 值为 0.7613。HyperNet 获得的最高 F1 分数为 0.8112。此外, ISFA 获得了最大的精度, CVA 位居第二, 表明检测到的变化几乎都是真正变化的区域。OSCD 检测到了所有的变化, 但代价是低 Kappa 和低精度。总体而言, 在赫米斯顿数据集上, HyperNet 获得了最佳的综合性能。所提出的双分支 SSA 模块旨在提取空间对象关系和有判别力的频谱特征, 有助于减少误检并改善变化检测, 使赫米斯顿数据集的变化检测结果有所不同。

图 13 展示了在 Bay 数据集上的二值变化检测结果。未标记的不确定区域为灰色。MSCD 和 OSCD 在绿色中检测到的遗漏变化比其他方法略多, 特别是在左侧农田区域。这两种方法最初是为多光谱遥感变化检测设计的, 在处理高光谱图像 (HSI) 时面临挑战。与 MTC-NET (patch = 31) 相比, 在 MTC-NET (patch = 13) 的检测图中可以发现更多的红色误检。然而, MTC-NET (patch = 31) 遗漏的变化在绿色中比 MTC-NET (patch = 13) 更多。

表 V
在湾数据集上对所有方法进行定量评估

Method	OA	Kappa	F1	Precision	Recall
CVA	0.8723	0.7462	0.8708	<u>0.9474</u>	0.8057
ISFA	<u>0.8917</u>	<u>0.7848</u>	0.8905	0.9695	0.8234
MSCD	0.7503	0.5089	0.7260	0.8777	0.6190
OSCD	0.7264	0.4533	0.7339	0.7644	0.7065
MTC-NET (patch size=13)	0.8821	0.7627	<u>0.8910</u>	0.8807	<u>0.9016</u>
MTC-NET (patch size=31)	0.8108	0.6240	0.8082	0.8818	0.7459
HyperNet	0.9079	0.8152	0.9129	0.9224	0.9037




图 14. 在圣巴巴拉数据集上的二值变化检测图: (a) CVA; (b) ISFA; (c) MSCD; (d) OSCD; (e) MTC-NET (补丁 = 13); (f) MTC-NET (补丁 = 31); (g) 所提出的超网络; 以及 (h) 参考变化图。

确实如此。批量大小的选择在检测性能中起着重要作用。相比之下, 具有无补丁架构的 HyperNet 避免了一个问题, 并以更少的误报获得了更好的变化检测结果。表 V 展示了 Bay 数据集的量化评估结果。在所有方法中, HyperNet 获得了最佳的结果, OA 为 0.9079, Kappa 为 0.8152, F1 分数为 0.9129, 召回率为 0.9037, 并且优于第二好的方法。而 ISFA 获得了最高的精度为 0.9695, 且误检最少。

圣巴巴拉数据集的二值变化检测结果如图 14 所示。观察到, 在 OSCD 和 MTC-NET (patch = 13) 的检测图中, 出现了大量的红色虚假检测, 对应于表六所示的低精度。在 CVA、MSCD 和 OSCD 的结果中, 可以发现明显的漏检, 与表六所示的低召回率一致。HyperNet 能够在低虚假检测率下检测到大多数变化。如表六所示, 在所有比较方法中, HyperNet 获得了最佳的整体准确率为 0.9114, Kappa 为 0.8148, F1 分数为 0.8880, 召回率为 0.8925, 而 ISFA 获得了最高的精度为 0.9071。总之, HyperNet 是

表六
在圣巴巴拉数据集上对所有方法进行定量评估

Method	OA	Kappa	F1	Precision	Recall
CVA	0.8780	0.7403	0.8376	0.8792	0.7997
ISFA	<u>0.8912</u>	<u>0.7675</u>	0.8535	0.9071	0.8059
MSCD	0.7868	0.5313	0.6872	0.8127	0.5952
OSCD	0.6869	0.3384	0.5914	0.6137	0.5751
MTC-NET (patch size=13)	0.8805	0.7550	<u>0.8566</u>	0.8288	<u>0.8920</u>
MTC-NET (patch size=31)	0.8886	0.7641	0.8539	0.8801	0.8301
HyperNet	0.9114	0.8148	0.8880	<u>0.8836</u>	0.8925




图 15. 关于 SSA 模块中 RSAB 和 RCAB 数量的 HACD 任务结果和 HBCD 结果: (a) 三个数据集的 AUC 性能; (b) 赫米斯顿数据集; (c) 贝伊数据集和 (d) 圣巴巴拉数据集二进制变化检测结果上的五个定量评估指标 (OA、Kappa、F1、精度和召回率)。

能够检测到更精确的变化检测结果, 以半监督学习 (SSL) 的方式捕捉农田的细微变化。

V. 讨论

A. 参数的敏感性和稳定性分析

网络的深度始终是一个首要因素, 它通常会影响到特征提取能力、过拟合问题和计算成本之间的平衡。所提出的 SSA 模块旨在从高光谱图像中挖掘空间关系和有判别性的频谱特征。为了测试 SSA 模块中 RSAB 和 RCAB 数量的稳定性和敏感性, 针对所有数据集在 HBCD 和 HACD 任务上都进行了实验。

具体而言, 基于所提出的超网络, 分别将 RSAB 和 RCAB 的数量设置为 1、2、3、4、5 进行分析。图 15 展示了实验结果。观察到, 对于 HACD 任务的三个数据集, AUC 值随着 RSAB 和 RCAB 数量的增加而降低(如图 15(a) 所示)。然而, 对于 HBCD, 随着 Hermiston 数据集中 RSAB 和 RCAB 数量的增加




图 16. 对来自 SSA 模块、投影仪和预测器的表示在 HACD 任务和 HBCD 任务中的性能进行评估: (a) HACD 任务的三个数据集的 AUC 性能; HBCD 在以下数据集上的五个定量评估指标 (OA、Kappa、F1、精度和召回率): (b) 赫米斯顿数据集; (c) 贝伊数据集; 以及 (d) 圣巴巴拉数据集。

从 1 到 4, OA、Kappa、F1 和精度增加, 而当数字变为 5 时, 这四个指标下降; 当数字从 2 增加到 5 时, 召回率下降。对于 Bay 数据集, 这五个指标最初随着数字从 1 增加到 3 而上升, 随后当数字大于 3 时下降。对于 Santa Barbara 数据集, 这五个指标随着数字的攀升逐渐增大。

显然, RSAB 和 RCAB 的性能因 HACD 任务和 HBCD 而异。所提出的超网络旨在通过多时相高光谱图像所选伪不变区域的语义特征对齐来学习特征表示。随着 RSAB 和 RCAB 块的增加, 获取了更深层次的特征, 最终特征图的感受野增大。具体而言, 对于 HACD 任务, 异常变化实际上很小且罕见; 因此, 所选的伪不变样本在整个图像中随机分布。更多的块会导致语义特征对齐的范围更大, 甚至异常变化的面积更大, 检测到的缺失问题更多, 这对应于更小的 AUC。对于 HBCD, 对于 Hermiston 和 Bay 数据集, 这五个指标先增加后下降, 而对于 Santa Barbara 数据集, 它们随 RSAB 和 RCAB 的数量增加而增加。很可能是更深层次的架构促进了语义特征的对齐, 尤其是对于所选的伪不变区域。然而, 所选伪未更改区域周围的更改区域涉及的初始领域越来越大, 导致未更改区域增多而更改区域减少, 这与 Hermiston 和 Bay 数据集的召回率下降相对应。

RASB 和 RCAB 的块数在平衡特征提取能力和过拟合问题方面起着重要作用。实验结果和分析表明, 将块数设定为 3 是一个综合考虑 HACD 任务和 HBCD 任务的合适选择。

表七

在三个 HACD 任务数据集上对具有和没有所提出的焦点余弦损失的超网络进行 AUC 比较

Method	EX-1	EX-2	Simulated Hymap
Base	0.8562	0.8966	0.9886
Base + SSA	<u>0.9081</u>	<u>0.9112</u>	<u>0.9923</u>
HyperNet	0.9147	0.9126	0.9927

B. 表示形式的评估

然后，我们研究并比较了 SSA 模块、投影器和预测器的表示在变化检测性能方面的表现。如图 16(a)和(b)所示，观察到对于所有三个 HACD 任务数据集以及 HBCD 的 Hermiston 数据集，SSA 模块的表示优于投影器和预测器。具体而言，可以观察到 AUC 值增加了 1% - 4%，Kappa、F1、精度和召回率的改进幅度高达 47% - 57%。此外，对于 Bay 数据集，投影器的表示甚至取得了稍好一些的结果，对于 Barbara 数据集，预测器的表示比 SSA 模块的表示表现稍好[如图 16(c)和(d)所示]。总体而言，SSA 模块的表示能够取得与投影器和预测器的表示相当甚至更优的结果。

图 1 分别给出了从 SSA 模块、投影器和预测器学习到的特征图的确切可视化结果。超网络需要学习对自然数据增强（特别是多时相高光谱图像采集条件）不变的特征表示。有人认为，由于投影特征嵌入被迫与预测目标相似，因此从投影器和预测器学习到的特征可能信息量较少。相比之下，从 SSA 模块学习到的表示保留了更合理和全面的信息以及孪生特征模式，这更有利于获得更好的变化检测结果。因此，考虑到整体性能和分析，选择 SSA 模块的表示用于 HACD 任务和 HBCD 的后处理。

C. 超网络的消融实验

为了测试所提出的 SSA 模块和焦点余弦损失函数在变化检测方面的性能，设计了大量的消融实验。具体而言，“基础”是使用带有余弦相似度的基本常规二维卷积层设计的。而“基础 + SSA”表示与“基础”相比采用了 SSA 模块。

表七给出了 HyperNet 在三个 HACD 任务数据集上的消融实验的 AUC 性能。最大的值以粗体显示，第二大的值以下划线显示。如表七所示，对于所有三个数据集，“Base + SSA”获得的 AUC 优于“Base”。并且 HyperNet 获得的 AUC 高于“Base + SSA”。为了直观地展示焦点余弦损失函数有效性的直观表示，图 17 展示了三个数据集消融实验的 ROC 比较。蓝色的“Base + SSA”获得了更高的检测概率。

表八

在三个 HBCD 数据集上对具有和没有所提出的焦点余弦损失的超网络进行定量比较

Dataset	Method	OA	Kappa	F1	Precision	Recall
Hermiston	Base	0.9140	0.7427	0.7969	0.8530	0.7489
	Base + SSA	<u>0.9197</u>	<u>0.7579</u>	<u>0.8083</u>	0.8751	<u>0.7516</u>
	HyperNet	0.9206	0.7613	0.8112	<u>0.8740</u>	0.7569
Bay	Base	0.8605	0.7211	0.8649	0.8964	0.8355
	Base + SSA	<u>0.9075</u>	<u>0.8144</u>	<u>0.9123</u>	0.9234	<u>0.9016</u>
	HyperNet	0.9079	0.8152	0.9129	<u>0.9224</u>	0.9037
Barbara	Base	0.8906	0.7730	0.8647	0.8441	0.8867
	Base + SSA	0.9155	0.8234	0.8934	0.8869	0.9001
	HyperNet	<u>0.9114</u>	<u>0.8148</u>	<u>0.8880</u>	<u>0.8836</u>	<u>0.8925</u>

这比黑色的“基础”效果更好。在“基础 + SSA”的结果中（如图 18 第二行所示），比“基础”的地图（如图 18 第一行所示）更突出异常变化，这表明了所提出的 SSA 模块的有效性。在所有三个数据集上，红色的 HyperNet 的 ROC 曲线优于蓝色的“基础 + SSA”（如图 17 所示），其中焦点余弦损失函数被鼓励与余弦相似度损失函数相比，更侧重于困难的正样本，促进网络的训练。

此外，在另外三个数据集上对 HBCD 的消融实验进行了定性和定量评估。如表八所示，对于所有三个数据集，使用 SSA 模块的“基础 + SSA”比“基础”获得了更高的 OA、Kappa、F1 分数、精度和召回率。并且验证了“基础 + SSA”的检测图（如图 19 第二行所示）中红色中的误报更少，绿色中的漏检变化更少，而“基础”的检测图（如图 19 第一行所示）则不然。此外，对于 Hermiston 和 Bay 数据集，具有余弦损失函数的超网络比“基础 + SSA”获得了更好的 OA、Kappa、F1 分数和召回率。然而，具有余弦损失函数的超网络在 Barbara 数据集上的结果比超网络本身更好，超网络的结果中红色误报略多（如图 19 第三行所示）。原因可能是硬阳性样本所占比例较低，并且与 Hermiston 和 Bay 数据集的情况相比，焦点余弦损失函数的作用较小，因为对于 Barbara 数据集，“Base”获得的综合 Kappa 值较高，为 0.7730，而对 Hermiston 数据集为 0.7427，对 Bay 数据集为 0.7211。

总的来说，HyperNet 能够获得更好的变化检测结果，其中 SSA 模块在充分挖掘空间关系和有判别性的频谱特征方面发挥了作用，而焦点余弦在放大对频谱差异复杂区域的注意力方面发挥了重要作用。

D. 运行时间成本分析

为了测试所有方法的运行时效率，表九展示了八种对比算法的运行时间成本比较。




图 17. 在三个 HACD 任务数据集（即：（a）EX1: D1F12H1 - D1F12H2；（b）EX - 2: D1F12H1 - D2F22H2；以及（c）模拟的 Hymap 数据集）上对 HyperNet 的消融实验的 ROC 比较。




图 18. 消融实验的异常变化检测图比较：（a）EX1: D1F12H1 - D1F12H2；（b）EX-2: D1F12H1 - D2F22H2；以及（c）模拟的 Hymap 数据集。（从上到下）来自基础模型、基础模型 + SSA 和超网络的结果。




图 19. 烧蚀实验的二值变化检测图比较：（a）赫米斯顿数据集；（b）贝数据集；（c）圣巴巴拉数据集。

表九
三个数据集的高光谱异常变化检测运行时间成本（单位：秒）

Method	EX-1	EX-2	Simulated Hymap
CC	6.4648	6.1926	4.7479
USFA	6.2399	5.7220	4.2144
Diff-RX	5.2346	5.2716	3.9411
HACD	5.8634	5.5663	4.0575
SDHACD	5.2340	5.2752	3.5482
SDACD	<u>5.1161</u>	<u>5.2610</u>	<u>3.4776</u>
MTC-NET (patch=13)	325.5863	323.9787	377.7896
MTC-NET (patch=31)	357.7804	711.4080	1114.5716
HyperNet	53.1382	53.4293	55.0648

并且在 HACD 任务的三个数据集上对超网络进行测试。最高的时间成本以粗体显示，最低的时间成本以下划线标明。

显然，在所有三个数据集上，MTC-NET（补丁 = 31）比其他方法都耗费了最多的时间。而 SDACD 在 HACD 任务上花费的时间成本最小。此外，前六种传统方法在所有三个数据集上都运行得很快。HyperNet 在所有三个数据集上大约花费 55 秒，对于 HACD 任务的更好性能来说，这是可以接受的。

表 X 展示了在 HBCD 任务上三个数据集的所有方法的运行时间成本。对于三个数据集，OSCD 的运行速度比其他方法慢得多，因为其样本 CL 的消耗较大。而 CVA 在所有数据集上获得的时间开销最小。尽管 HyperNet 所花费的时间比 CVA 稍多，但在最后五种基于深度学习的方法中，HyperNet 运行得最快。因此，鉴于能获得更好的综合变化检测结果，时间成本的增加是可以接受的。

表 X 基于三个数据集的 HBCD 运行时间成本 (单位: 秒)

Method	Hermiston	Bay	Barbara
CVA	<u>4.0485</u>	<u>9.2552</u>	<u>24.2482</u>
ISFA	5.2825	18.9484	41.3809
MSCD	258.1106	1230.0600	3395.0281
OSCD	577.4696	3485.8024	9934.2895
MTC-NET (patch=13)	213.2759	602.3598	1291.5176
MTC-NET (patch=31)	489.0661	658.9878	1200.4907
HyperNet	36.8909	143.7598	261.8970

VI. 结论

在本文中, 我们试图提出一种用于高光谱变化检测的自监督光谱理解网络。HyperNet 采用 SSL 模式, 并以全卷积的方式实现多时空光谱特征比较, 以进行逐像素的特征表示学习。设计出的空间注意力分支专注于二维成像空间的空间相关性, 而频谱注意力分支则专注于各种地表的具有判别性的频谱特征。并且创建了一个新颖的相似性损失函数, 名为焦点余弦, 用于在 SSL 训练中更好地调整不平衡的简单和困难正样本。在六个高光谱数据集上进行的大量实验表明, 所提出的 HyperNet 在 HACD 任务和 HBCD 任务上的有效性和泛化能力。此外, 事实证明, 设计出的 SSA 分支和焦点余弦损失函数能够在 HACD 任务中检测到更多的异常变化, 减少误检并提高 HBCD 的检测率。

参考文献

- [1] D. Lu, P. Mausel, E. Brondizio, and E. Moran, "Change detection techniques," *Int. J. Remote Sens.*, vol. 25, no. 12, pp. 2365–2401, Jun. 2004, doi: [10.1080/0143116031000139863](#).
- [2] R. S. Lunetta, J. F. Knight, J. Edirivickrema, J. G. Lyon, and L. D. Worthy, "Land-cover change detection using multi-temporal MODIS NDVI data," *Remote Sens. Environ.*, vol. 105, no. 2, pp. 142–154, 2006, doi: [10.1016/j.rse.2006.06.018](#).
- [3] Z. Zhu, "Change detection using Landsat time series: A review of frequencies, preprocessing, algorithms, and applications," *ISPRS J. Photogramm. Remote Sens.*, vol. 130, pp. 370–384, Aug. 2017, doi: [10.1016/j.isprsjprs.2017.06.013](#).
- [4] A. Singh, "Review article digital change detection techniques using remotely-sensed data," *Int. J. Remote Sens.*, vol. 10, no. 6, pp. 989–1003, 1989, doi: [10.1080/01431168908903939](#).
- [5] R. J. Radke, S. Andra, O. Al-Kofahi, and B. Roysam, "Image change detection algorithms: A systematic survey," *IEEE Trans. Image Process.*, vol. 14, no. 3, pp. 294–307, Mar. 2005, doi: [10.1109/TIP.2004.838698](#).
- [6] W. Dong, T. Zhang, J. Qu, S. Xiao, J. Liang, and Y. Li, "Laplacian pyramid dense network for hyperspectral pansharpening," *IEEE Trans. Geosci. Remote Sens.*, vol. 60, pp. 1–13, 2022, doi: [10.1109/TGRS.2021.3076768](#).
- [7] W. Dong, S. Hou, S. Xiao, J. Qu, Q. Du, and Y. Li, "Generative dual-adversarial network with spectral fidelity and spatial enhancement for hyperspectral pansharpening," *IEEE Trans. Neural Netw. Learn. Syst.*, early access, Jun. 10, 2021, doi: [10.1109/TNNLS.2021.3084745](#).
- [8] L. Zhang and B. Du, "Recent advances in hyperspectral image processing," *Geo-Spatial Inf. Sci.*, vol. 15, no. 3, pp. 143–156, Sep. 2012, doi: [10.1080/10095020.2012.719684](#).
- [9] P. Ghamisi et al., "Advances in hyperspectral image and signal processing: A comprehensive overview of the state of the art," *IEEE Aerosp. Electron. Syst. Mag.*, vol. 5, no. 4, pp. 37–78, Dec. 2017, doi: [10.1109/MGRS.2017.2762087](#).
- [10] J. Theiler, "Quantitative comparison of quadratic covariance-based anomalous change detectors," *Appl. Opt.*, vol. 47, no. 28, p. F12, Oct. 2008, doi: [10.1364/AO.47.000F12](#).
- [11] N. Acito, M. Diani, G. Corsini, and S. Resta, "Introductory view of anomalous change detection in hyperspectral images within a theoretical Gaussian framework," *IEEE Aerosp. Electron. Syst. Mag.*, vol. 32, no. 7, pp. 2–27, Jul. 2017, doi: [10.1109/MAES.2017.160155](#).
- [12] Q. Du, N. Younan, and R. King, "Change analysis for hyperspectral imagery," in *Proc. Int. Workshop Anal. Multi-Temporal Remote Sens. Images*, Jul. 2007, pp. 1–4, doi: [10.1109/MULTITEMP.2007.4293052](#).
- [13] S. Liu, D. Marinelli, L. Bruzzone, and F. Bovolo, "A review of change detection in multitemporal hyperspectral images: Current techniques, applications, and challenges," *IEEE Geosci. Remote Sens. Mag.*, vol. 7, no. 2, pp. 140–158, Jun. 2019, doi: [10.1109/MGRS.2019.2898520](#).
- [14] J. Shi, Z. Zhang, T. Wu, X. Zhang, and Y. Lei, "Collaborative self-perception network architecture for hyperspectral image change detection," *IEEE Geosci. Remote Sens. Lett.*, vol. 19, pp. 1–5, 2022, doi: [10.1109/LGRS.2022.3157916](#).
- [15] C. Shi, Z. Zhang, W. Zhang, C. Zhang, and Q. Xu, "Learning multi-scale temporal-spatial features via a multipath convolutional LSTM neural network for change detection with hyperspectral images," *IEEE Trans. Geosci. Remote Sens.*, vol. 60, pp. 1–16, 2022, doi: [10.1109/TGRS.2022.3176642](#).
- [16] Y. Yang, J. Qu, S. Xiao, W. Dong, Y. Li, and Q. Du, "A deep multiscale pyramid network enhanced with spatial-spectral residual attention for hyperspectral image change detection," *IEEE Trans. Geosci. Remote Sens.*, vol. 60, pp. 1–13, 2022, doi: [10.1109/TGRS.2022.3161386](#).
- [17] T. Bai et al., "Deep learning for change detection in remote sensing: A review," *Geo-Spatial Inf. Sci.*, early access, pp. 1–27, Jul. 2022, doi: [10.1080/10095020.2022.2085633](#).
- [18] L. Wang, L. Wang, Q. Wang, and L. Bruzzone, "RSCNet: A residual self-calibrated network for hyperspectral image change detection," *IEEE Trans. Geosci. Remote Sens.*, vol. 60, pp. 1–17, 2022, doi: [10.1109/TGRS.2022.3177478](#).
- [19] J. Qu, S. Hou, W. Dong, Y. Li, and W. Xie, "A multilevel encoder-decoder attention network for change detection in hyperspectral images," *IEEE Trans. Geosci. Remote Sens.*, vol. 60, pp. 1–13, 2022, doi: [10.1109/TGRS.2021.3130122](#).
- [20] L. Ericsson, H. Gouk, and T. M. Hospedales, "Why do self-supervised models transfer? Investigating the impact of invariance on downstream tasks," 2021, *arXiv:2111.11398*.
- [21] L. Ericsson, H. Gouk, and T. M. Hospedales, "How well do self-supervised models transfer?" in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Nashville, TN, USA, Jun. 2021, pp. 5410–5419, doi: [10.1109/CVPR46437.2021.00537](#).
- [22] Y. Wang, C. M. Albrecht, N. A. A. Braham, L. Mou, and X. X. Zhu, "Self-supervised learning in remote sensing: A review," 2022, *arXiv:2206.13188*.
- [23] Y. Tian, C. Sun, B. Poole, D. Krishnan, C. Schmid, and P. Isola, "What makes for good views for contrastive learning," in *Proc. Adv. Neural Inf. Process. Syst.*, vol. 33, 2020, pp. 6827–6839.
- [24] A. Jaiswal, A. R. Babu, M. Z. Zadeh, D. Banerjee, and F. Makedon, "A survey on contrastive self-supervised learning," *Technologies*, vol. 9, no. 1, p. 2, Dec. 2020, doi: [10.3390/technologies9010002](#).
- [25] Y. Chen and L. Bruzzone, "Self-supervised change detection in multiview remote sensing images," *IEEE Trans. Geosci. Remote Sens.*, vol. 60, pp. 1–12, 2022, doi: [10.1109/TGRS.2021.3089453](#).
- [26] S. Saha, P. Ebel, and X. X. Zhu, "Self-supervised multisensor change detection," *IEEE Trans. Geosci. Remote Sens.*, vol. 60, pp. 1–10, 2022, doi: [10.1109/TGRS.2021.3109957](#).
- [27] N. Acito, M. Diani, A. Rossi, and S. U. De Ceglie, "Hyperspectral anomalous change detection in the presence of non-stationary atmospheric/illumination conditions," in *Proc. SPIE, Amsterdam, The Netherlands*, Oct. 2014, p. 92440, doi: [10.1117/12.2067314](#).
- [28] S. Resta, N. Acito, M. Diani, G. Corsini, T. Opsahl, and T. V. Haavardsholm, "Detection of small changes in airborne hyperspectral imagery: Experimental results over urban areas," in *Proc. 6th Int. Workshop Anal. Multi-Temporal Remote Sens. Images (Multi-Temp)*, Jul. 2011, pp. 5–8, doi: [10.1109/Multi-Temp.2011.6005033](#).
- [29] J. Theiler and S. Perkins, "Proposed framework for anomalous change detection," in *Proc. ICML Workshop Mach. Learn. Algorithms Surveill. Event Detection*, 2006, p. 8.
- [30] A. P. Schaum and A. Stocker, "Hyperspectral change detection and supervised matched filtering based on covariance equalization," in *Proc. Defense Secur.*, Orlando, FL, USA, Aug. 2004, p. 77, doi: [10.1117/12.544026](#).

- [31] S. Alan and S. Alan, "Long-interval chronochrome target detection," in *Proc. Int. Symp. Spectral Sens. Res.*, 1998, pp. 1760–1770.
- [32] M. T. Eismann, J. Meola, and R. C. Hardie, "Hyperspectral change detection in the presence of diurnal and seasonal variations," *IEEE Trans. Geosci. Remote Sens.*, vol. 46, no. 1, pp. 237–249, Jun. 2008, doi: [10.1109/TGRS.2007.907973](#).
- [33] M. Hu, C. Wu, L. Zhang, and B. Du, "Hyperspectral anomaly change detection based on autoencoder," *IEEE J. Sel. Topics Appl. Earth Observ. Remote Sens.*, vol. 14, pp. 3750–3762, 2021, doi: [10.1109/JSTARS.2021.3066508](#).
- [34] P. Coppin, I. Jonckheere, K. Nackaerts, B. Muys, and E. Lambin, "Review article digital change detection methods in ecosystem monitoring: A review," *Int. J. Remote Sens.*, vol. 25, no. 9, pp. 1565–1596, 2004, doi: [10.1080/0143116031000101675](#).
- [35] M. Hussain, D. Chen, A. Cheng, H. Wei, and D. Stanley, "Change detection from remotely sensed images: From pixel-based to object-based approaches," *ISPRS J. Photogramm. Remote Sens.*, vol. 80, pp. 91–106, Jun. 2013, doi: [10.1016/j.isprsjprs.2013.03.006](#).
- [36] Z. Hou, W. Li, L. Li, R. Tao, and Q. Du, "Hyperspectral change detection based on multiple morphological profiles," *IEEE Trans. Geosci. Remote Sens.*, vol. 60, 2021, Art. no. 5507312.
- [37] Z. Hou, W. Li, R. Tao, and Q. Du, "Three-order tucker decomposition and reconstruction detector for unsupervised hyperspectral change detection," *IEEE J. Sel. Topics Appl. Earth Observ. Remote Sens.*, vol. 14, pp. 6194–6205, 2021, doi: [10.1109/JSTARS.2021.3088438](#).
- [38] L. Zhang, L. Zhang, and B. Du, "Deep learning for remote sensing data: A technical tutorial on the state of the art," *IEEE Geosci. Remote Sens. Mag.*, vol. 4, no. 2, pp. 22–40, Jan. 2016, doi: [10.1109/MGRS.2016.2540798](#).
- [39] W. Shi, M. Zhang, R. Zhang, S. Chen, and Z. Zhan, "Change detection based on artificial intelligence: State-of-the-art and challenges," *Remote Sens.*, vol. 12, no. 10, p. 1688, May 2020, doi: [10.3390/rs12101688](#).
- [40] Q. Wang, Z. Yuan, Q. Du, and X. Li, "GETNET: A general end-to-end 2-D CNN framework for hyperspectral image change detection," *IEEE Trans. Geosci. Remote Sens.*, vol. 57, no. 1, pp. 3–13, Jan. 2019, doi: [10.1109/TGRS.2018.2849692](#).
- [41] J. Lei, M. Li, W. Xie, Y. Li, and X. Jia, "Spectral map-ping with adversarial learning for unsupervised hyperspectral change detection," *Neurocomputing*, vol. 465, pp. 71–83, Nov. 2021, doi: [10.1016/j.neucom.2021.08.130](#).
- [42] Q. Li et al., "Unsupervised hyperspectral image change detection via deep learning self-generated credible labels," *IEEE J. Sel. Top. Appl. Earth Observ. Remote Sens.*, vol. 14, pp. 9012–9024, 2021, doi: [10.1109/JSTARS.2021.3108777](#).
- [43] L. Wang, L. Wang, Q. Wang, and P. M. Atkinson, "SSA-SiamNet: Spectral-spatial-wise attention-based Siamese network for hyperspectral image change detection," *IEEE Trans. Geosci. Remote Sens.*, vol. 60, pp. 1–18, 2022, doi: [10.1109/TGRS.2021.3095899](#).
- [44] C. Wu, B. Du, and L. Zhang, "Fully convolutional change detection framework with generative adversarial network for unsupervised, weakly supervised and regional supervised change detection," 2022, *arXiv:2201.06030*.
- [45] C. Tao, J. Qia, G. Zhang, Q. Zhu, W. Lu, and H. Li, "TOV: The original vision model for optical remote sensing image understanding via self-supervised learning," 2022, *arXiv:2204.04716*.
- [46] L. Jing and Y. Tian, "Self-supervised visual feature learning with deep neural networks: A survey," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 43, no. 11, pp. 4037–4058, Nov. 2021, doi: [10.1109/TPAMI.2020.2992393](#).
- [47] S. Azizi et al., "Big self-supervised models advance medical image classification," in *Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV)*, Montreal, QC, Canada, Oct. 2021, pp. 3458–3468, doi: [10.1109/ICCV48922.2021.00346](#).
- [48] T. Han, W. Xie, and A. Zisserman, "Self-supervised co-training for video representation learning," in *Proc. Adv. Neural Inf. Process. Syst.*, vol. 33, 2020, pp. 5679–5690.
- [49] Y. Li, D. Huang, D. Qin, L. Wang, and B. Gong, "Improving object detection with selective self-supervised self-training," in *Computer Vision—ECCV*. Cham, Switzerland: Springer, 2020, pp. 589–607, doi: [10.1007/978-3-030-58526-6_35](#).
- [50] C. Doersch, A. Gupta, and A. A. Efros, "Unsupervised visual representation learning by context prediction," in *Proc. IEEE Int. Conf. Comput. Vis. (ICCV)*, Santiago, Chile, Dec. 2015, pp. 1422–1430, doi: [10.1109/ICCV.2015.167](#).
- [51] P. Sermanet, C. Lynch, J. Hsu, and S. Levine, "Time-contrastive networks: Self-supervised learning from multi-view observation," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. Workshops (CVPRW)*, Jul. 2017, pp. 486–487, doi: [10.1109/CVPRW.2017.69](#).
- [52] K. He, H. Fan, Y. Wu, S. Xie, and R. Girshick, "Momentum contrast for unsupervised visual representation learning," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Seattle, WA, USA, Jun. 2020, pp. 9726–9735, doi: [10.1109/CVPR42600.2020.00975](#).
- [53] T. Chen, S. Kornblith, M. Norouzi, and G. Hinton, "A simple framework for contrastive learning of visual representations," in *Proc. 37th Int. Conf. Mach. Learn.*, Nov. 2020, pp. 1597–1607.
- [54] J.-B. Grill et al., "Bootstrap your own latent—A new approach to self-supervised learning," in *Proc. Adv. Neural Inf. Process. Syst.*, vol. 33, 2020, pp. 21271–21284.
- [55] X. Chen and K. He, "Exploring simple Siamese representation learning," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Nashville, TN, USA, Jun. 2021, pp. 15745–15753, doi: [10.1109/CVPR46437.2021.01549](#).
- [56] S. Woo, J. Park, J. Y. Lee, and I. S. Kweon, "CBAM: Convolutional block attention module," in *Proc. Eur. Conf. Comput. Vis. (ECCV)*, 2018, pp. 3–19.
- [57] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Las Vegas, NV, USA, Jun. 2016, pp. 770–778, doi: [10.1109/CVPR.2016.90](#).
- [58] I. S. Reed and X. Yu, "Adaptive multiple-band CFAR detection of an optical pattern with unknown spectral distribution," *IEEE Trans. Acoust., Speech Signal Process.*, vol. 38, no. 10, pp. 1760–1770, Oct. 1990.
- [59] J. A. Hartigan and M. A. Wong, "Algorithm AS 136: A K-means clustering algorithm," *J. Roy. Stat. Soc. C, Appl. Statist.*, vol. 28, no. 1, pp. 100–108, 1979, doi: [10.2307/2346830](#).
- [60] N. Acito, S. Matteoli, A. Rossi, M. Diani, and G. Corsini, "Hyperspectral airborne 'Viareggio 2013 Trial' data collection for detection algorithm assessment," *IEEE J. Sel. Topics Appl. Earth Observ. Remote Sens.*, vol. 9, no. 6, pp. 2365–2376, Jun. 2016, doi: [10.1109/JSTARS.2016.2531747](#).
- [61] N. Acito, M. Diani, and G. Corsini, "Residual striping reduction in hyperspectral images," in *Proc. 17th Int. Conf. Digit. Signal Process. (DSP)*, Jul. 2011, pp. 1–7, doi: [10.1109/ICDSP.2011.6005002](#).
- [62] K. He, X. Zhang, S. Ren, and J. Sun, "Delving deep into rectifiers: Surpassing human-level performance on ImageNet classification," in *Proc. IEEE Int. Conf. Comput. Vis. (ICCV)*, Santiago, Chile, Dec. 2015, pp. 1026–1034, doi: [10.1109/ICCV.2015.123](#).
- [63] M. Caron, P. Bojanowski, J. Mairal, and A. Joulin, "Unsupervised pre-training of image features on non-curved data," in *Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV)*, Oct. 2019, pp. 2959–2968.
- [64] C. Wu, L. Zhang, and B. Du, "Hyperspectral anomaly change detection with slow feature analysis," *Neurocomputing*, vol. 151, pp. 175–187, Mar. 2015, doi: [10.1016/j.neucom.2014.09.058](#).
- [65] M. Hu, C. Wu, and B. Du, "Multi-temporal spatial-spectral comparison network for hyperspectral anomalous change detection," 2022, *arXiv:2205.11395*.
- [66] C. Wu, B. Du, and L. Zhang, "Slow feature analysis for change detection in multispectral imagery," *IEEE Trans. Geosci. Remote Sens.*, vol. 52, no. 5, pp. 2858–2874, May 2014, doi: [10.1109/TGRS.2013.2266673](#).



胡美琪 (IEEE 研究生会员) 于 2019 年在中国长沙的中南大学地球科学与信息物理学院获得测绘工程学士学位。目前, 她正在中国武汉的武汉大学测绘遥感信息工程国家重点实验室攻读博士学位。

她的研究兴趣包括深度学习和多时相遥感图像变化检测。



陈武 (IEEE 会员) 于 2010 年在中国南京的东南大学获得测绘工程学士学位, 并于 2015 年在中国武汉的武汉大学测绘遥感信息工程国家重点实验室获得摄影测量与遥感博士学位。

他目前是武汉大学测绘遥感信息工程国家重点实验室的教授。他的研究兴趣包括多时相遥感

多光谱和高光谱图像中的感知图像变化检测与分析



张良培 (IEEE 会士) 1982 年在中国长沙的湖南师范大学获得物理学学士学位, 1988 年在中国西安的西安光学精密机械研究所获得光学硕士学位, 1998 年在中国武汉的武汉大学获得摄影测量与遥感博士学位。

2011 年至 2016 年, 他是由国家科学部任命的中国国家重点基础研究项目的首席科学家。

他领导着中国的遥感项目。目前, 他是武汉大学测绘遥感信息工程国家重点实验室的讲座教授。他已发表了 700 多篇学术论文和 5 本书。他是科学信息研究所 (ISI) 高被引作者。他拥有 30 项专利。他的研究兴趣包括高光谱遥感、高分辨率遥感、图像处理和人工智能。

张博士是工程技术学会 (IET) 会员。他曾获得 2010 年最佳论文波音奖、2013 年美国摄影测量与遥感学会 (ASPRS) 最佳论文 ERDAS 奖, 以及 2016 年国际光学与光子学会 (SPIE) 最佳论文理论创新奖。他的研究团队在 2014 年 IEEE 地球科学与遥感学会 (GRSS) 数据融合竞赛中获得了前三名, 近年来他的学生也多次入选 IEEE 国际地球科学与遥感研讨会 (IGARSS) 学生论文竞赛的获奖者或入围者。他是 IEEE GRSS 武汉分会的创始主席。他还担任了十多个国际期刊的副主编或编辑。他是 IEEE 地球科学与遥感学报的副主编。